# 基于超分辨率算法的光谱数据传递方法研究

姓　　名_____范乘旭_____

# 摘　　要

光谱数据在地物识别、化学成分分析等许多领域都有重要应用，但不同设备或环境下获取到的光谱数据存在差异不便于一起使用，所以通过光谱数据传递来消除这种差异为后续应用提供便利就显得尤为重要。本设计拟采用超分辨率算法解决光谱数据传递问题，涉及到的主要研究内容有：

首先，针对一维光谱数据搭建不同的一维超分辨率模型进行光谱数据传递，并且通过折线图对比和评价指标的好坏确定一种在一维下性能良好的超分辨率模型；其次，针对超分辨率算法在图像领域的大量应用和发展，比如亚像素卷积等专门对二维数据处理的超分辨率算法，本设计将光谱数据预处理为二维伪灰度图进行传递，确定在何种维度下光谱数据传递效果更加优秀；然后，以选定的维度和模型对少量样本数据进行小样本学习，并针对问题改进模型增加性能，评估小样本条件下的光谱数据传递效果；最后，通过实验对比，本设计在一维维度下所使用的引导注意力模型对光谱数据传递的效果非常显著，在绘制的折线图上基本与原数据吻合，峰值信噪比在大样本光谱数据条件下达到了79.49，在小样本光谱数据条件下达到了77.49，明显优于其他模型（峰值信噪比在65-75之间）和传统的超分辨率传递方法（峰值信噪比在60-65之间），证明了本设计所提方法的合理和有效性。

**关键字**：深度学习；超分辨率算法；光谱数据；引导注意力；

# ABSTRACT

Spectral data have important applications in many fields, such as ground object recognition and chemical composition analysis. But, same spectral data obtained may different due to different devices or environment and not easy to be used together. So, it is particularly important to eliminate such differences through spectral data transmission in order to provide convenience for subsequent applications. This design intends to adopt Super-Resolution algorithm to solve the problem of spectral data transmission, and the main research contents involved are as follows:

Firstly, different Super-Resolution models were built for one-dimensional spectral data transmission, and a Super-Resolution model with good performance in one-dimensional was determined through graph comparison and evaluation index. Secondly, in view of the large number of applications and development of Super-Resolution algorithms in the image field, such as sub-pixel convolution and other Super-Resolution algorithms, this design transforms spectral data into two-dimensional pseudo-gray image for transmission, and determines in which dimension the spectral data transmission effect is more excellent. Then, the selected dimension and model are used to learn a small number of sample data, and the model will be optimized to improve the performance. Finally, through experimental comparison, it is found that the Guided Attention model used in this design has a very significant effect on spectral data transmission in the one dimension, which is basically consistent with the original data in the graph. The PSNR reaches 79.49 in the case of large sample spectral data and 77.49 in the case of small sample spectral data. It is obviously superior to other models (PSNR between 65-75) and traditional super resolution transmission method (PSNR between 60-65), which proves the rationality and effectiveness of the proposed method in this design.

**Key Words**: Deep Learning, Super-Resolution, Spectral Data, Guided Attention

# 目　　录

1 绪论 . . . . . 1
1.1 选题背景及研究意义 . . . . . 1
1.2 超分辨率算法研究现状 . . . . . 1
1.3 论文内容与组织结构 . . . . . 2
1.3.1 论文内容 . . . . . 2
1.3.2 论文结构 . . . . . 3
2 光谱数据传递理论基础 . . . . . 4
2.1 光谱数据介绍 . . . . . 4
2.2 超分辨率算法原理 . . . . . 5
2.3 优化函数和评价指标 . . . . . 7
3 超分辨率模型搭建及光谱数据预处理 . . . . . 9
3.1 超分辨率模型搭建 . . . . . 9
3.2 光谱数据预处理 . . . . . 11
4 针对小样本光谱数据的改进 . . . . . 13
4.1 小样本光谱数据预处理 . . . . . 13
4.2 超分辨率模型改进 . . . . . 14
5 实验结果分析 . . . . . 16
5.1 大样本光谱数据传递效果比较 . . . . . 16
5.2 不同维度光谱数据传递效果分析 . . . . . 21
5.3 小样本光谱数据传递效果分析 . . . . . 22
6 结论与展望 . . . . . 25
6.1 结论 . . . . . 25
6.2 展望 . . . . . 25
参考文献 . . . . . 26

# 1 绪论

本章将主要介绍本设计的选题背景、研究意义和目前超分辨率算法的研究现状，并对论文整体结构进行说明。

## 1.1 选题背景及研究意义

光谱在物质分析检测等方面具有举足轻重的地位，天文学、化学、生物学、地质学等不少领域均通过光谱来获取所需要的信息[1]-[4]，但是光谱数据会因为设备不同、环境不同等因素产生差异，导致光谱预测模型无法很好的兼容，为后续工作带来麻烦，因此通过光谱数据传递方法[5][6]来消除各种因素导致的差异以此增强预测模型的兼容性就显得尤为重要。

近年来深度学习的蓬勃发展给光谱数据的传递方法带来了新的思路[7]，即通过基于深度学习的超分辨率算法来完成对光谱数据的传递。基于深度学习的超分辨率算法自2014年被提出并首先被应用在二维图像的分辨率提升上，它的设计思路是尽管图像在分辨率上存在差异，但同一图像在不同分辨率下的边缘细节、形状、色彩等均有一定的联系，超分辨率算法就是通过学习这之中的联系来将低分辨率图像提升到高分辨率图像。而本设计所要完成的光谱数据传递与图像超分辨率流程具有一定的相似性，也就是尽管同一光谱数据在不同因素影响下存在一定差异，但它们的波形结构、分布等信息也存在着一定的联系，而这种联系同样可以被超分辨率模型所学习到。

所以，本设计针对上述情况，旨在探索一种基于超分辨率算法的光谱数据传递方法，利用深度神经网络的高效学习能力完成光谱数据的传递。本设计的研究意义是：通过超分辨率模型学习不同因素下光谱数据的特征与联系，并将其传递到所需要的光谱数据形式，将外部因素对光谱数据获取的影响降低，为后续光谱预测模型提供便利。

## 1.2 超分辨率算法研究现状

传统的超分辨率算法包括插值法[8]、重建法[9]、浅层学习法[10]，例如插值法中最近邻插值[11]、双线性插值[12]、双三次插值[13]等，其优势是算法简单，计算速度

快，缺点也非常明显，在处理边缘、突变处等位置效果不佳，易出现块效应等；重建法包括空域法[14]、频域法[15]、迭代反投影法[16]等，优势是在锐化边缘细节处理较好，但是缺点是对图像整体的复原效果差，无法很好的复现现实场景；浅层学习法主要以机器学习[17]、流形学习[18]为主，优势是可以用于样本数据较小的情况，缺点是需要人为设计特征过程较为复杂。

基于深度学习的超分辨率算法自2014年SRCNN(Super-Resolution Convolutional Neural Network)[19]首次提出，将深度学习的应用带入到超分辨率领域当中，使人们首次看到了神经网络在超分辨率方面的发展空间，于是基于深度学习的超分辨率算法开始出现，目前基于深度学习的超分辨率算法主要以卷积神经网络、残差网络[20]、稠密网络[21]、生成对抗网络[22]、注意力机制[23][24]、循环网络[25]等结构及其组合为主，模型的发展从性能、速度等方面不断优化，既能够兼顾速度，同时也在超分辨率恢复精度、细节、锐化等方面表现出卓越的优势。

基于深度学习的超分辨率算法发展至今已经早已与最初的SRCNN单纯由卷积层构成大有不同了，比如在2020年由Yong Guo、Jian Chen、Jingdong Wang等人提出的DRN(Closed-loop Matters: Dual Regression Networks for Single Image Super-Resolution)[26]模型，成功获得了SOTA(State Of The Art)效果，与在这之前的模型训练后只能负责重建特定一种分辨率精度相比，该模型能通过对偶回归原理逐级恢复不同分辨率大小的图像，模型运作机制类似于空间金字塔，通过输出复用以及残差、注意力等结构的组合，首先复原出分辨率较高的图像，再通过学习该高分辨率图像来向下复原出包含高分辨率细节的较低分辨率图像，该模型通过这种方式构建了一个庞大的复杂模型，不仅在单分辨率要求下能够做到很好的复现，而且在复数个分辨率要求下，同样可以输出优秀结果。

综上所述，本设计将使用基于深度学习的超分辨率算法完成对光谱数据的传递任务。但由于目前绝大部分的超分辨率算法是针对二维图像数据的超分辨率，对于本设计所使用的一维光谱数据并不适用，因此，本设计的主要问题之一就是探寻一种合理的模型结构或数据变换来完成对光谱数据的超分辨率传递。

## 1.3 论文内容与组织结构

### 1.3.1 论文内容

本设计主要围绕超分辨率算法对光谱数据的传递展开，涉及到超分辨率模型

搭建、光谱数据处理、小样本光谱数据传递等工作，并在此基础上对不同超分辨率模型、不同光谱数据处理方式的效果进行评估。研究内容有：

（1）大样本光谱数据传递效果比较：通过搭建超分辨率算法模型完成对大样本光谱数据数据的传递，并通过评价指标评估各模型性能，确定效果优秀的超分辨率模型。

（2）光谱数据维度比较：对光谱数据进行维度处理，分为原一维数据结构与处理后的二维数据结构，通过相同结构的一维超分辨率模型与二维超分辨率模型分别对两种光谱数据进行传递以此确定光谱数据处理的合适维度。

（3）小样本光谱数据传递效果比较：针对小样本数据特征少的特点，对数据进行人为拓展，之后选取前述实验中确定的较好的超分辨率模型进行传递，对结果进行评估后针对出现的问题对模型进行优化，最终搭建一个能够完成对小样本光谱数据传递的模型。

### 1.3.2 论文结构

本设计共分为六章内容，每章的大概内容如下：

第一章：主要介绍本设计的研究意义、研究现状以及主要内容、文章结构。

第二章：主要介绍光谱数据的特点、超分辨率算法中各个模块的作用、评价指标和模型优化方式。

第三章：主要介绍以注意力模型为主的超分辨率模型搭建以及光谱数据的处理方式。

第四章：主要针对小样本数据，在数据预处理和模型结构两方面进行改进，探索一种有效传递小样本光谱数据的超分辨率模型。

第五章：对超分辨率模型的光谱数据传递效果在折线图、评价指标等方面进行分析，主要包括：大样本光谱数据传递效果评价；不同维度光谱数据传递效果评价；对小样本光谱数据的传递效果评价。

第六章：主要为本设计的结论与展望。

# 2 光谱数据传递理论基础

在进行超分辨率对光谱数据的传递之前，本章将首先对光谱数据、超分辨率算法的基本理论进行简单介绍，主要包括：LIBS(Laser-Induced Breakdown Spectroscopy)[27]光谱数据的获取方式、光谱数据在不同因素下的差异和消除这种差异的必要性；组成超分辨率模型的基本结构和各个结构的主要功能；以及对超分辨率模型传递结果的评价指标和参数优化方式。

## 2.1 光谱数据介绍

光谱数据的采集使用了LIBS(Laser-Induced Breakdown Spectroscopy)方法，即激光诱导击穿光谱仪。如图2.1所示，LIBS光谱通过将激光施加在被测物体上，使物体表面形成激光光斑，这些激光光斑其实是包含着物体信息的等离子体，随着组成物体的原子在激光下变为基态，它们就会发射出专属波长的光，而每一种元素都有其独特的波长，这些激光光斑经由收集镜收集并通过光谱系统进行分析，就能够获知组成物体的成分等信息。

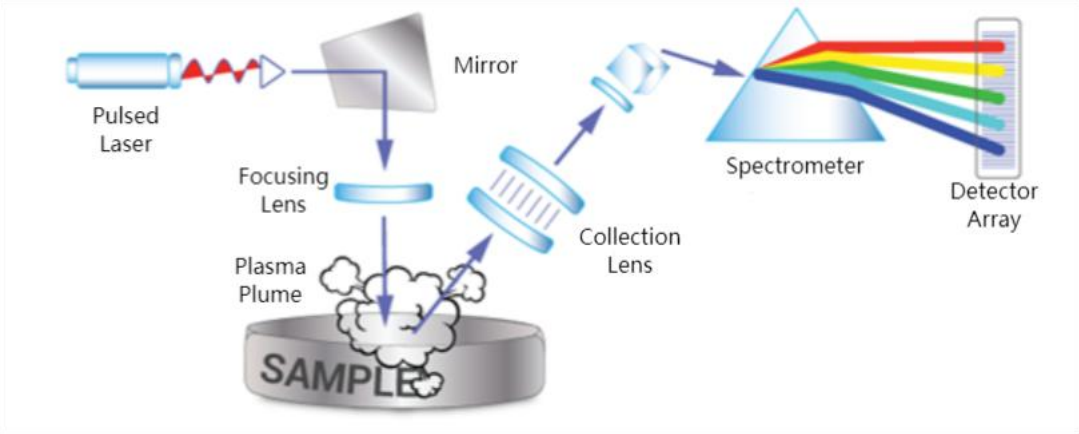


**图2.1 LIBS光谱数据获取流程**

本设计所用的光谱数据为火星车Chemcam数据、Supercam数据和山东大学与火星车互传的光谱数据，其中Supercam与Chemcam互传的数据集为大样本数据集，数据量为1560条；Chemcam与山东大学互传数据集为小样本数据集，数据量为39条，主要用于针对少量数据量下的光谱数据传递训练。

本设计所使用的光谱数据为一维数据，单条数据根据设备不同长度在6000-8000之间。数据特点主要由集中于某一段的多个峰值和较大占比的低值为主，数据的折线图如图2.2所示。

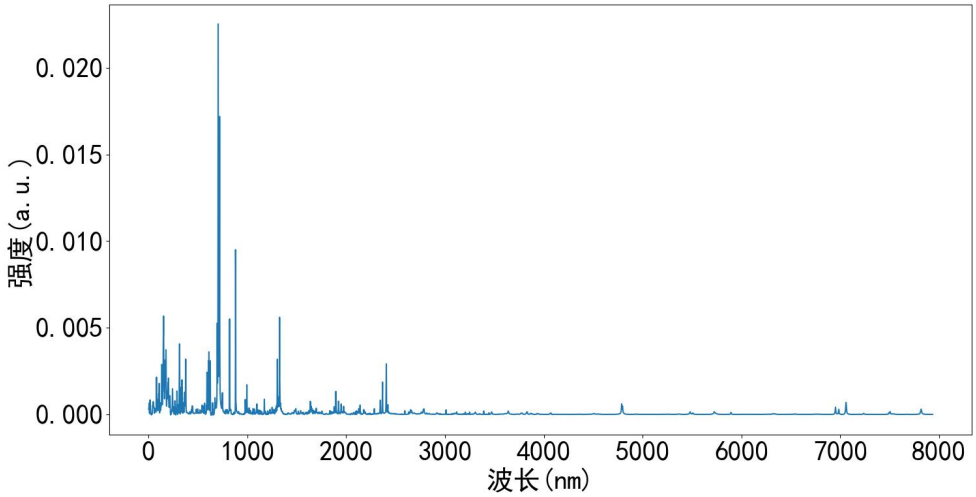


**图2.2 Supercam光谱数据**

同一种物质的光谱数据在不同设备下的数据形式如图2.3所示，可以看出不同设备的同种光谱数据存在着很大的差异，如果同时使用这两种数据，会造成后续预测模型的不兼容，无法很好的预测出结果，所以必须使用光谱数据传递来消除这些差异。

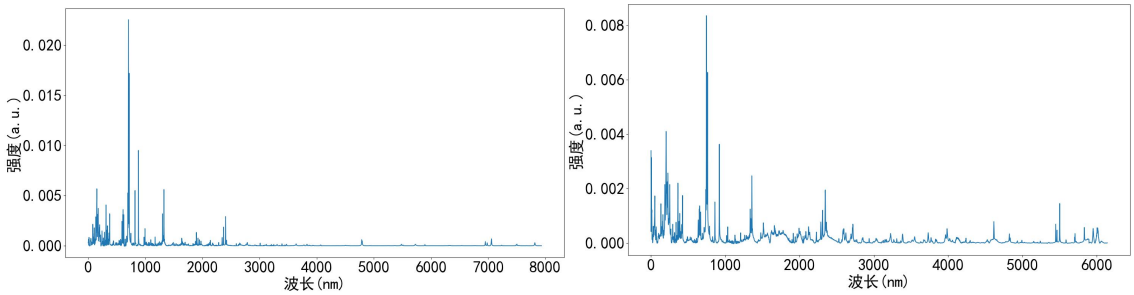


**(a)Supercam设备获取到的光谱数据** **(b)Chamcam设备获取到的光谱数据**

**图2.3 不同设备下同一光谱的差异**

## 2.2 超分辨率算法原理

本设计采用的超分辨率算法主要以深度学习为主，如负责特征提取的卷积层、负责非线性映射的激活函数等基本结构。在介绍超分辨率模型之前，先对超分辨率算法各个模块的功能作用进行简单介绍：

基于深度学习的超分辨率算法从SRCNN开始发展，模型结构基本由负责提取低分辨率图像的特征块并表示为高维向量的特征提取层、将高维向量非线性映射到另一个高维向量的非线性映射层、负责最终重建高分辨率输出结果的重建层这三个部分组成，如下图2.4所示的SRCNN模型即为这种结构。

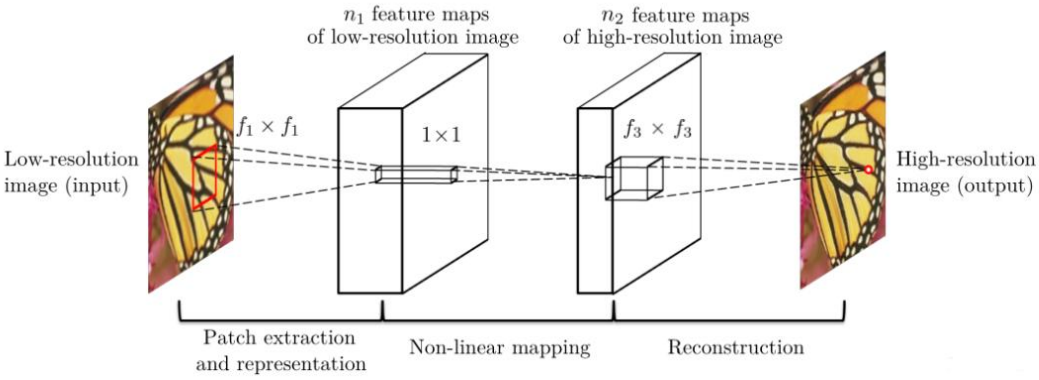


**图2.4 SRCNN模型结构**

各层的运作流程如下。首先，如图2.5，输入数据经由特征提取层将相邻数据的相关性信息提取出来，这一层的结构通常由卷积层组成，它可以输出多个通道的特征信息，每一个通道的特征信息都有所不同，这样做可以尽可能多的获取到输入数据中的原始特征信息。

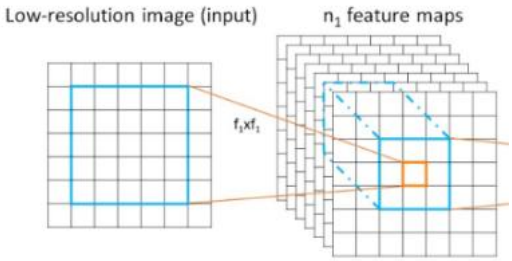


**图2.5 特征提取层**

然后，如图2.6，特征信息经非线性映射层映射至另一高维向量，这一步操作在不同模型中由不同的结构负责，如残差模型中主要由残差块负责映射、注意力模型中由注意力结构负责映射等，该层将体现出原特征信息的高维信息，便于最后重建层对数据的处理。

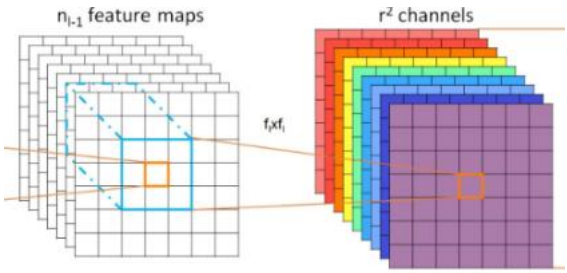


**图2.6 非线性映射层**

最后，如图2.7所示，高维特征信息经由重建层进行输出，输出通道数量与输入通道数量一致，同样由卷积构成，输出的结果就是分辨率提升后的数据。整体流程的核心就是获取到目标数据点及其周围数据点的相关性，并依照这个相关性来重建出高分辨率数据。

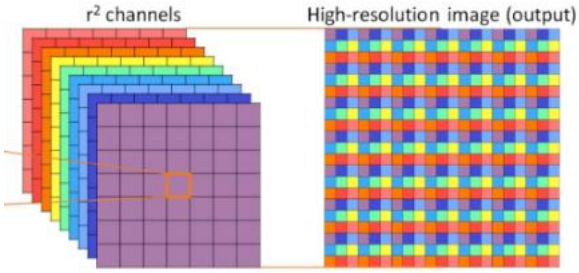


**图2.7 重建层**

各层的结构不但可以通过如上图所示的卷积构成，也可以由其他结构如残差、循环、注意力等结构组成，各种结构的不同也有其不同的作用，如残差网络可以有效解决梯度消失问题从而大幅加深网络，使网络的特征提取能力更加优异；注意力网络对各通道的特征提取数据分配不同权重用以区别对各种特征的重视程度等等。

## 2.3 优化函数和评价指标

本设计所选用的损失函数以L2loss为主，主要使用MSE(Mean Square Error)损失，MSE的计算如式2-1所示。

$$\mathrm{MSE} = \frac{1}{\mathrm{m}}\sum_{\mathrm{i}=1}^{\mathrm{m}}(\mathrm{y_i} - \mathrm{t_i})^2 \tag{2-1}$$

在优化方式方面本设计选用自适应矩估计法Adam(Adaptive Moment Estimation)[28]，优化方式如式2-2所示，首先优化器对损失函数的参数求导得到梯度$g_t$，再通过梯度求得梯度在动量形式下的一阶矩估计$m_t$、二阶矩估计$v_t$，然后对$m_t$、$v_t$进行偏差纠正，最后通过求得偏差纠正后的矩估计值对参数$\theta_{t+1}$进行更新。

$$g_t = \nabla\hat{L}(\theta_t) \tag{2-2a}$$

$$m_t = \beta_1 m_{t-1} + (1-\beta_1)g_t \tag{2-2b}$$

$$v_t = \beta_2 v_{t-1} + (1-\beta_2)g_t^2 \tag{2-2c}$$

$$\widehat{m}_t = \frac{m_t}{1-\beta_1^t} \tag{2-2d}$$

$$\widehat{v}_t = \frac{v_t}{1-\beta_2^t} \tag{2-2e}$$

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\widehat{v}_t}+\varepsilon}\widehat{m}_t \tag{2-2f}$$

在超分辨率算法领域中，对输出结果好坏的评价通常使用PSNR(Peak Signal to Noise Ratio)[29]，即峰值信噪比来进行，主要用于衡量目标图像与原图像之间的相似性，PSNR的值越高，代表着两个图像之间的相似性越高，本设计也将使用PSNR

作为对光谱数据传递结果的评价，PSNR计算方式如式2-3所示，MSE为均方误差。

$$\mathrm{PSNR} = 10 \times \log_{10}\left[\frac{(2^{n}-1)^{2}}{\mathrm{MSE}}\right] \tag{2-3}$$

式中n为单个数据位数，在RGB图像PSNR计算中，RGB图像的单像素值在0-255之间为8位，故n取8。在本设计中，由于光谱数据大小不一，且在处理过程中经过了归一化的操作，同时考虑到n一经确定在所有光谱数据传递评价中应该均保持为固定值。所以本设计直接将分子部分视为常数，取为1，最终结果仅在整体的大小上略有不同，评价好坏仍然是PSNR的值越大越好。

# 3 超分辨率模型搭建及光谱数据预处理

本章主要介绍以下两部分内容：首先是针对大样本光谱数据的超分辨率模型搭建，将介绍注意力模型和构成注意力模型的子结构卷积结构、残差结构。

然后介绍对光谱数据的预处理手段，包括对一维光谱数据的预处理和对光谱数据进行升维后转为伪灰度图的预处理。

## 3.1 超分辨率模型搭建

本设计针对光谱数据的一维特点，搭建了处理一维数据的超分辨率模型，同时考虑到卷积神经网络对二维数据的强大处理能力，本设计也同样考虑对光谱数据进行升维后通过二维超分辨率模型处理。超分辨率模型在结构上基本一致，仅有维度不同。本设计的模型搭建以注意力机制为主，首先从大样本光谱数据传递的角度，搭建了注意力模型，然后针对小样本光谱数据传递对注意力结构进行优化改进为引导注意力模型，接下来本设计将首先介绍对大样本光谱数据传递的模型，模型顺序从子结构开始，逐步组成为注意力模型。

（1）卷积结构：卷积结构是深度学习中最基础的结构，所有模型的构成都缺少不了卷积结构的参与，所以本设计从最简单的卷积结构进行搭建，所搭建网络模型如图3.1所示。该网络结构主要参照SRCNN的网络模型进行搭建，输入数据首先经过双三次插值法将长度提升至与目标数据一致，然后经过两个卷积核及ReLu激活函数进行特征提取和非线性映射，最后通过一个卷积核输出最终传递结果。

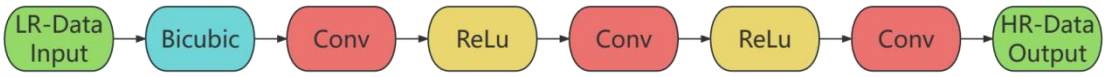


**图3.1 卷积网络模型结构**

（2）残差结构：残差结构能够有效解决深度学习模型过深造成的梯度消失问题，在增加模型深度时是必不可少的结构，经典的残差结构如图3.2所示，与卷积模型的主要区别为通过跳跃连接将输入数据与卷积层处理后的特征直接相加，即保留了原始数据的特征，同时也加入了卷积层提取出的特征，使后续信息更加丰富。

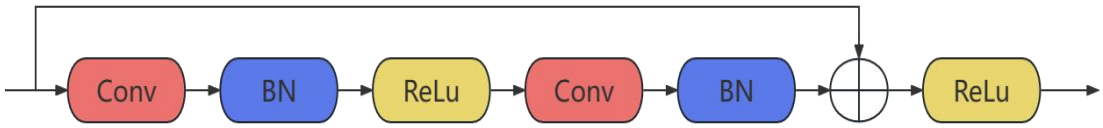


**图3.2 传统残差结构**

本设计所使用的残差块的结构相较于传统的残差结构，去除了BN层和最后输出层的激活函数，使得模型结构更小；同时加入了Mult层将卷积输出进行放缩控制数据大小在合理范围内，这种结构可以有效增加网络深度，或在同深度的情况下显著提升训练速度。本设计所搭建的残差结构如图3.3所示，该模型结构主要以数个残差块的组合为主，残差块同样通过残差链接进行信息传递，输入数据经过双三次插值处理后首先通过一个卷积层进行低层特征提取，然后进入堆叠的残差块结构中进行高层特征提取，最后输出传递结果。

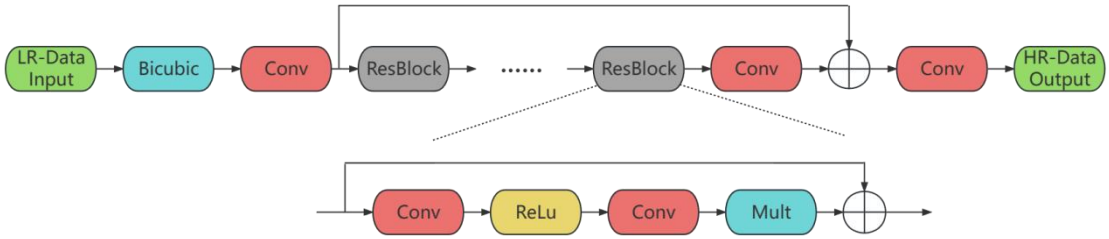


**图3.3 残差网络模型结构**

（3）注意力模型：本设计所使用的注意力模型由以上卷积结构、残差结构和通道注意力机制组成，通过注意力结构提取出兴趣区域的特征并在后续传递过程中加以使用。本设计所使用的注意力结构如图3.4所示，该模型参考RCAN（Very deep residual channel attention networks）模型结构，引入了Residual In Residual结构加深网络深度，在处理好的输入数据通过低层特征提取后，会进入残差群进行高层特征提取与注意力信息增强，最后通过一层卷积层传递得到输出数据。

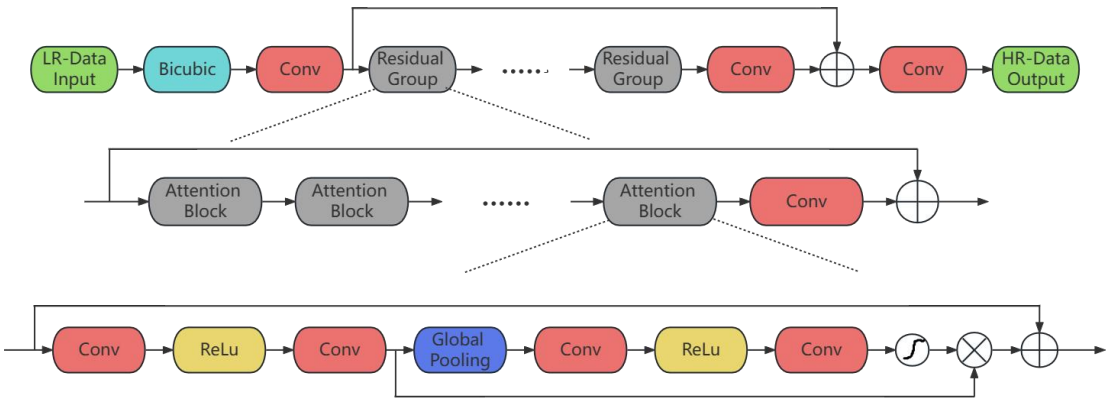


**图3.4 注意力模型结构**

每一个残差群的结构由多个注意力模块和一个卷积核构成，通过残差链接将低层信息与高层信息相结合。

注意力结构将特征信息首先经由卷积层进行特征提取，经过全局平均池化后通过卷积层与Sigmoid激活函数变为通道注意力权值，与特征信息相乘得到基于注意力权值的特征信息，最后与原特征信息相叠加，即有效保留原始特征信息，同时也增加了模型对重点特征的注意力信息。

## 3.2 光谱数据预处理

本设计所使用的光谱数据为一维数据，而深度学习常用来处理二维数据问题，因此本设计准备了一维、二维两种数据维度，从数据维度方面对光谱数据的恢复效果进行比较。

在一维数据处理方面，对原始光谱数据使用双三次插值法调整长度与目标光谱数据一致。双三次插值法由原数据点A，目标数据点B，目标数据点对应于原数据位置P（不一定在数据点上），原数据值a，目标数据值b以及权重W(x)组成。设原始数据长度为M，目标数据长度为N，则目标数据点B(y)所对应的原始数据位置为P(y*M/N)，取距离点P最近的四个数据点，即左右各两个相邻点作为原始数据A，则每一个点对应的权重W(x)的计算方式如式3-1所示，其中x表示点P与点A之间的距离，α一般取-0.5。

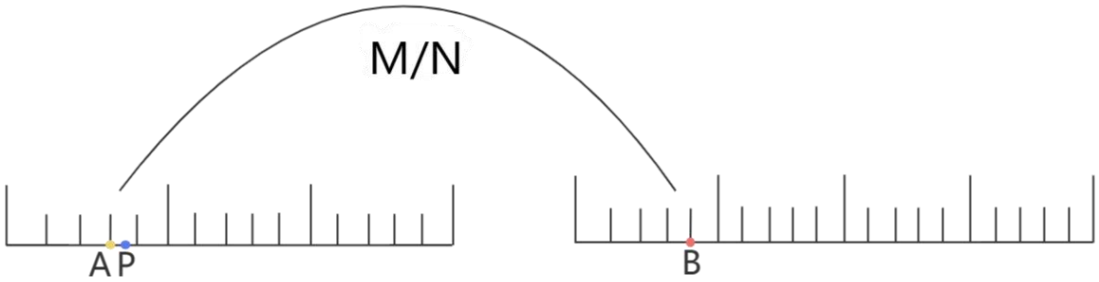


**图3.5 目标数据点与原数据点位置关系**

$$W(x)=\begin{cases}(\alpha+2)|x|^3-(\alpha+3)|x|^2+1 & \text{for } |x|\le 1\\ \alpha|x|^3-5\alpha|x|^2+8\alpha|x|-4\alpha & \text{for } 1<|x|<2\\ 0 & \text{otherwise}\end{cases} \tag{3-1}$$

得到权值后就可以通过原始数据点A对应的原始数据值a以及算得的权值W(x)计算目标数据点B的数据值，计算方式如式3-2所示。

$$B(y)=\sum_{i=1}^{4} a_i\times W_i \tag{3-2}$$

对于二维光谱数据的转换：考虑到超分辨率算法中，亚像素卷积、二维卷积核等操作对二维数据处理的优越性能，本设计考虑从输入数据处理方面，将光谱数据处理为二维数据。首先，通过双三次插值法对数据进行裁剪拼接成二维数据，拼接也要对目标光谱数据进行。由于目标光谱数据长度为7933无法拼接成规则二维数据，因此拼接前还要对数据进行加长，本设计将光谱数据加长至8000，以此拼接为100*80的二维数据，在加长方式上不选用双三次插值，这是因为会改变目标光谱数据的数值及分布，因此此处的加长选择对原数据进行补0的方式；然后，对拼接后的二维数据进行归一化，使数据范围限制在0-255以内；最后，将归一化后的二维数据进行伪灰度图转化，最终将光谱数据的伪灰度图参与传递。

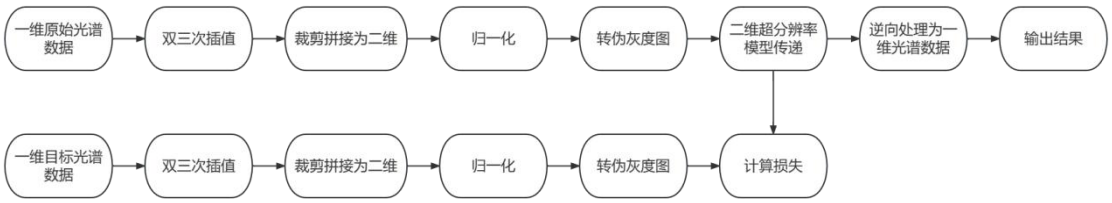


**图3.6 二维光谱数据处理流程**

数据处理流程如图3.6所示，输出结果时与预处理流程相反，将伪灰度图重新归一化到0-1区间内，然后对100*80的二维光谱数据拼接为8000长度的一维光谱数据并将传递结果输出即可。

# 4 针对小样本光谱数据的改进

上一章主要针对大样本数据进行了模型搭建和数据预处理，但是这些操作都是基于大样本数据建模数据非常丰富的基础上才能成立的。而小样本数据的一大特点就是建模数据并不丰富，很可能适用于大样本数据的模型无法有效学习到小样本数据的特征，从而导致光谱数据传递效果不佳。

因此本设计根据小样本光谱数据的特点将注意力模型进一步改进为引导注意力模型。同时注意到光谱数据的前后信息关联性，引入循环网络有效利用数据中的序列信息；

## 4.1 小样本光谱数据预处理

本设计所使用的小样本数据为Chemcam与山东大学的光谱数据互传，数据集共39个，按照8：2的比例分为训练集与测试集，即训练集31个，测试集7个。在该训练集中原始光谱数据长度为6016；目标光谱数据长度为6143。数据波形如图4.1所示。

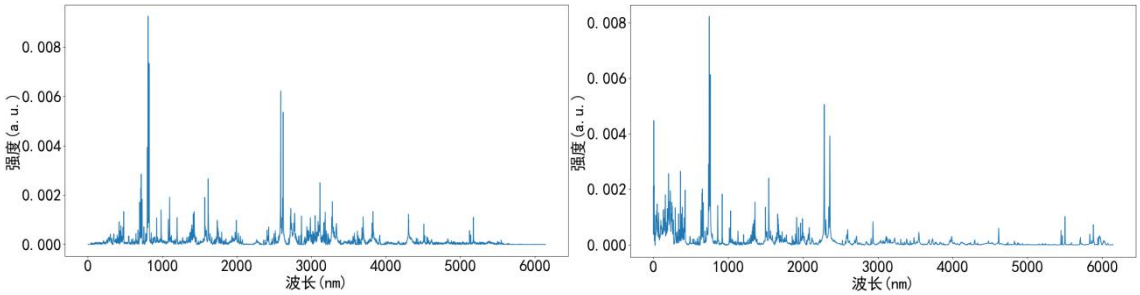


**(a)原始光谱数据** **(b)目标光谱数据**

**图4.1 小样本数据**

考虑到直接增大训练轮次而不对小样本光谱数据进行处理会导致过拟合；所以对小样本光谱数据进行人为数据增强，以此强化模型泛化能力，避免过拟合问题的出现。本设计的数据增强使用放缩的方式进行，即通过双三次插值法将数据长度缩短使其丢失一部分信息，再通过双三次插值法提升回原长度得到新的光谱数据。

具体流程为首先对原始光谱数据进行双三次插值，将数据长度提升至与目标光谱数据一致。然后对原始光谱数据进行数据增强，将原始光谱数据通过双三次插值法减少长度，再将其通过双三次插值法提升回原长度，得到减少过信息的原始光谱数据。通过不断重复构造减少不同长度的原始光谱数据来拓展原始数据量。

最后将得到的新数据与目标光谱数据进行对应，组为一个新的训练数据，以此拓展训练集大小，整个流程处理如图4.2所示。

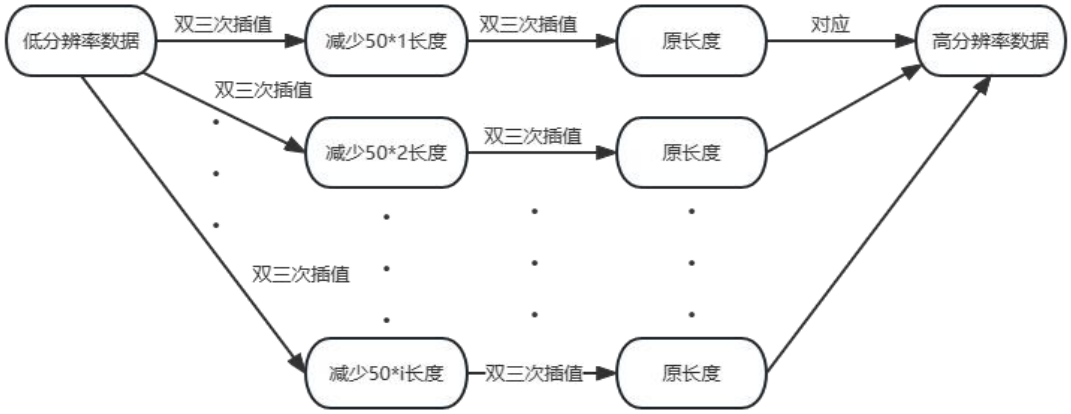


**图4.2 小样本数据扩展流程**

通过这种方法虽然可以提升数据集容量同时避免模型在小样本学习过程中出现过拟合问题，但本质上由于很大一部分的光谱数据都是由原始光谱数据衍生出来的，它们的主要特征信息与原始光谱数据还是很相似，在这种情况进行小样本光谱数据传递的训练还会出现欠学习的问题，因此本设计在对光谱数据预处理后，还要针对小样本光谱数据特点对超分辨率模型进行改进。

## 4.2 超分辨率模型改进

小样本数据由于建模数据过少，尽管经过数据拓展扩大了数据量，但是通过双三次插值法进行拓展这种方式本身就造成了训练数据复用过多，因此，在对小样本光谱数据本身处理完成后，还要继续对超分辨率模型进行改进，以此来契合对小样本数据的学习。

考虑到光谱数据作为一维数据，其数据结构存在一定的序列性，在某一位置的数据结构通常与其前后一部分区域的数据相关。而循环模型通常用于序列结构的预测，所以本设计考虑在注意力模型之后引入RNN(Recurrent Neural Networks)结构，充分利用小样本数据的序列信息以此增强模型对光谱数据的传递效果。

同时在实验过程中发现，加入RNN结构的注意力模型尽管传递效果有所上升，但对部分区域的传递效果并不理想，因此针对上述问题，本设计对注意力结构继续加以改进，变为引导注意力结构。本设计所使用的引导注意力模型如图4.3所示，模型使用空间注意力机制，用Mask方式提取数据中的兴趣区域，训练共分为两个

部分，每个部分之间共享权值训练，第一部分对完整的光谱数据进行超分辨率传递，学习数据整体特征；第二部分对加入Mask后的兴趣区域进行超分辨率传递，人为引导注意力模块将注意力放在兴趣区域。该模型对特定区域的特征学习使得传递后光谱数据在兴趣区域部分有着更为丰富的细节。

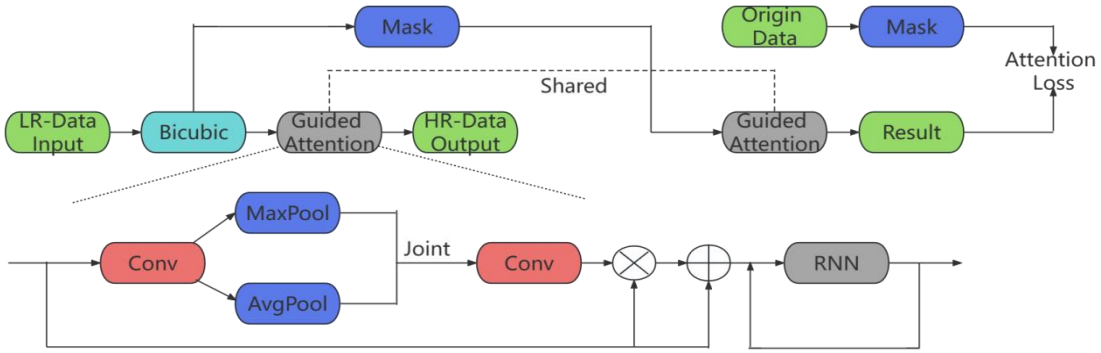


**图4.3 引导注意力模型结构**

本设计所采用的循环结构（上图RNN结构）如图4.4所示，结构采用预激活方法，将激活层置于卷积层之前，整体网络结构采用了全局残差和局部残差相结合的方式来加深网络深度。同时为了减少模型参数，在高层特征提取部分采取循环结构。

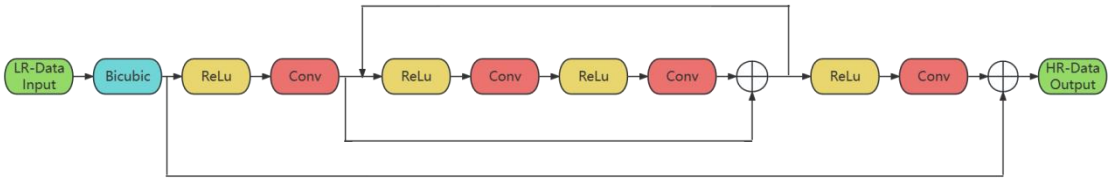


**图4.4 循环网络模型结构**

对光谱数据人为增加Mask后的原始光谱数据和目标光谱数据折线图如图4.5所示，Mask遮挡光谱数据不感兴趣的部分，在数据中在对应部分用置0体现，在训练时仅有感兴趣的区域参与传递，通过这种方式来驱使注意力结构对兴趣区域增加更多关注，通过后续章节的实验结果分析能够表明引导注意力模型对兴趣区域的传递效果确实要比未引导过的模型要优秀。

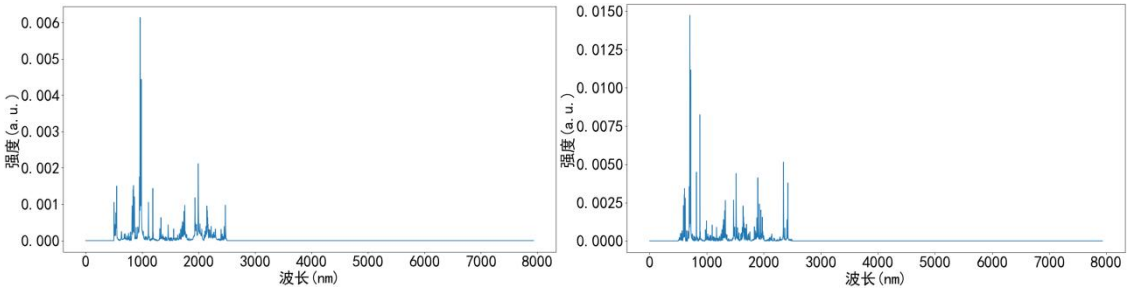


**(a)原始光谱数据** **(b)目标光谱数据**

**图4.5 加入Mask后的光谱数据**

# 5 实验结果分析

本章主要对前面所搭建的超分辨率模型对光谱数据的传递结果进行分析，分析指标从折线图的视觉差异以及PSNR评价指标的高低进行比较，包括以下内容：(1)对大样本数据的超分辨率模型光谱数据传递结果分析。(2)对不同维度的光谱数据传递效果分析。(3)对小样本小样本数据传递效果分析。

## 5.1 大样本光谱数据传递效果比较

目标光谱数据、原始光谱数据与双三次插值法处理后的原始光谱数据如图5.1所示。比较图中数据可以看出，原始光谱数据相较于目标光谱数据，在波形方面存在部分相似性，但在波形值方面，中值段较高，低值段噪声过多，尽管可以获取到足够信息，但与目标光谱数据的整体相似性并不高；对于双三次插值法处理后的原始光谱数据，通过比较图像可以看出，双三次插值法能够很好的保留原始光谱数据的波形及数值比例，不会造成太严重的信息丢失，但同时由于双三次插值法对原始光谱数据的效果仅停留在对数据长度的有效延展上，因此双三次插值法并不能有效复现目标光谱数据。

同时，为了使本设计的光谱数据传递效果比较更加全面，本设计不但使用上述介绍的卷积模型、残差模型、注意力模型三种结构，也将针对小样本光谱数据传递的循环模型、引导注意力模型两种结构加入到传递效果分析中。

本设计所选用的五种种超分辨率网络对原始光谱数据进行传递结果与目标光谱数据比对的折线图如图5.2所示，五个结果依次为卷积模型、残差模型、注意力模型、循环模型、引导注意力模型的传递结果。

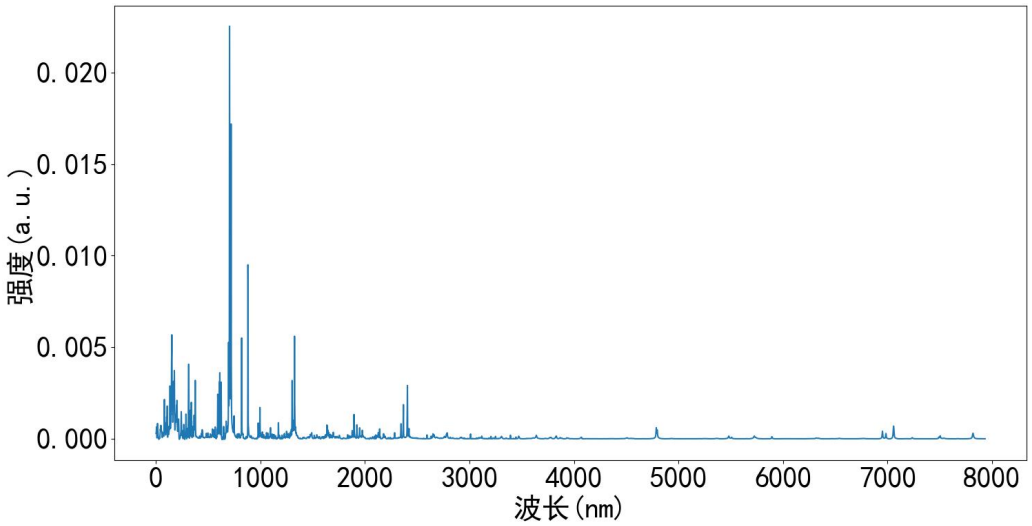


(a)目标光谱数据

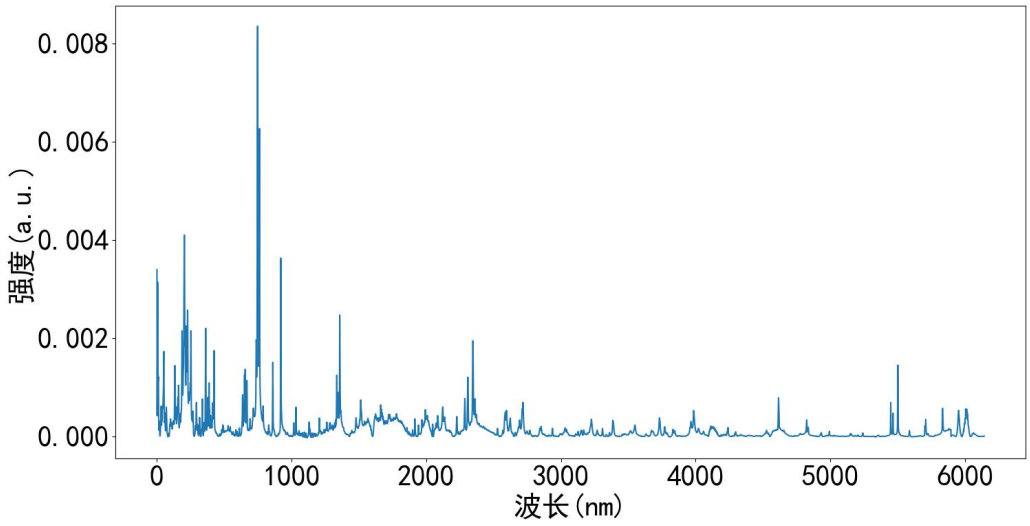


(b)原始光谱数据

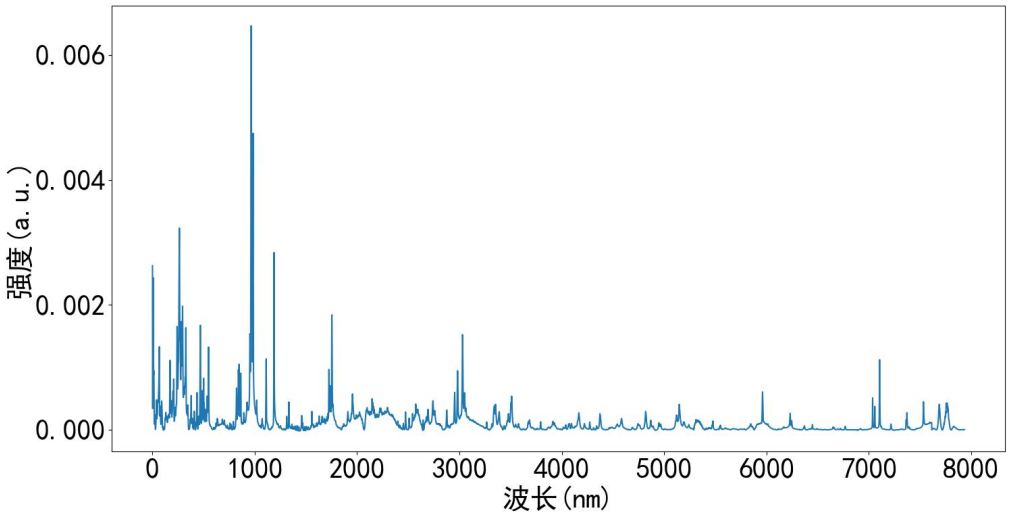


(c)双三次插值法后的原始光谱数据

**图5.1 不同设备下的光谱数据**

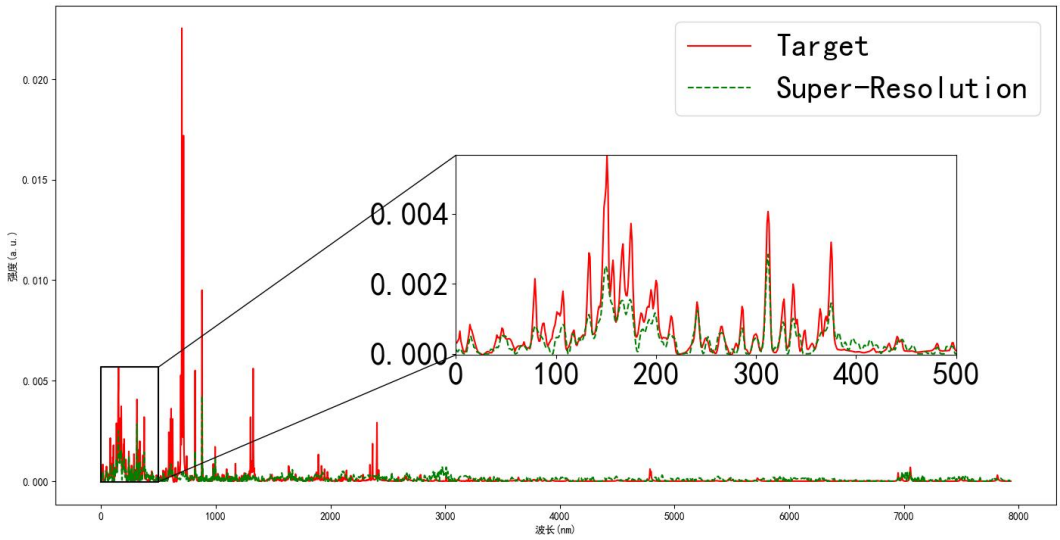


**(a)卷积模型**

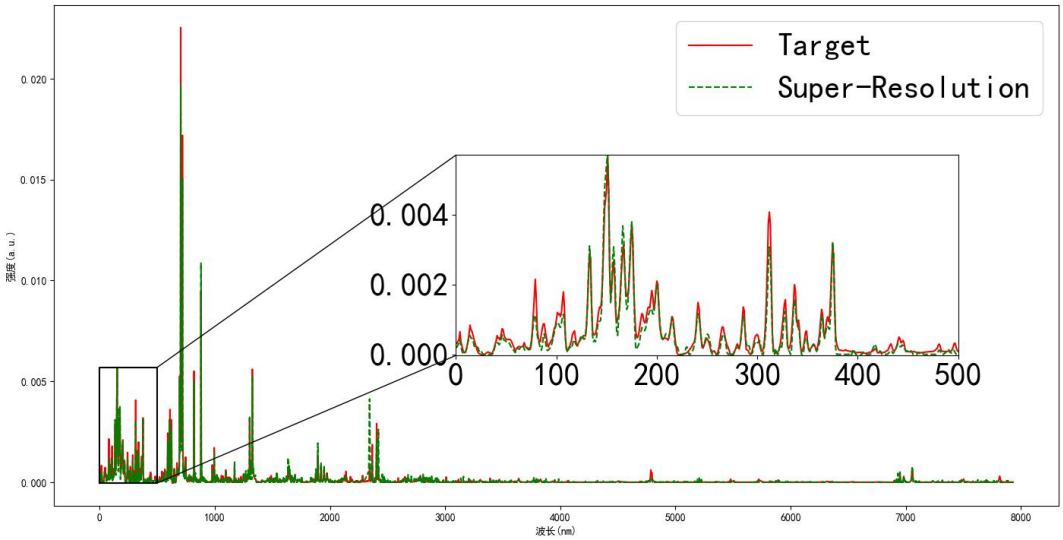


**(b)残差模型**

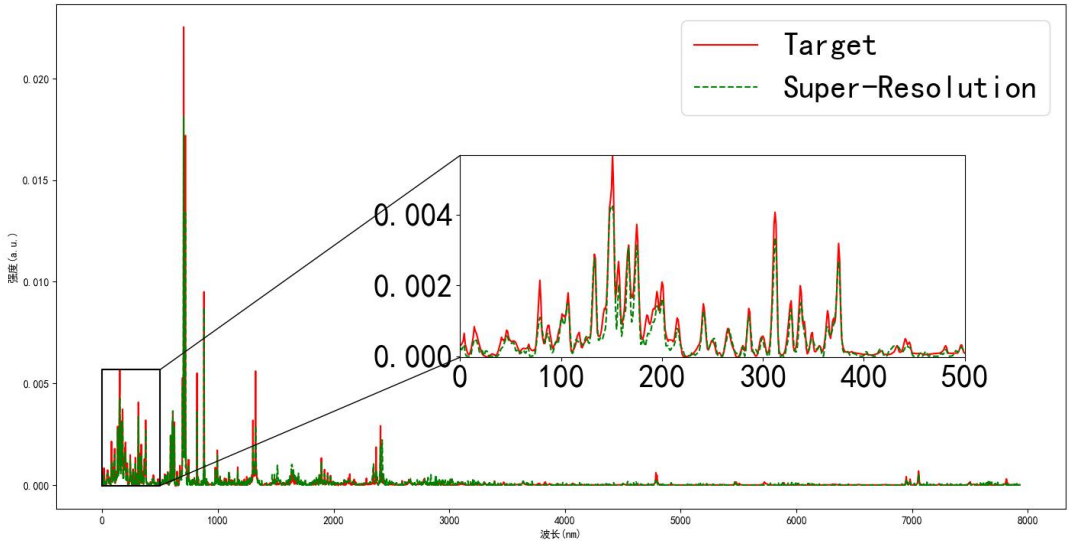


**(c)注意力模型**

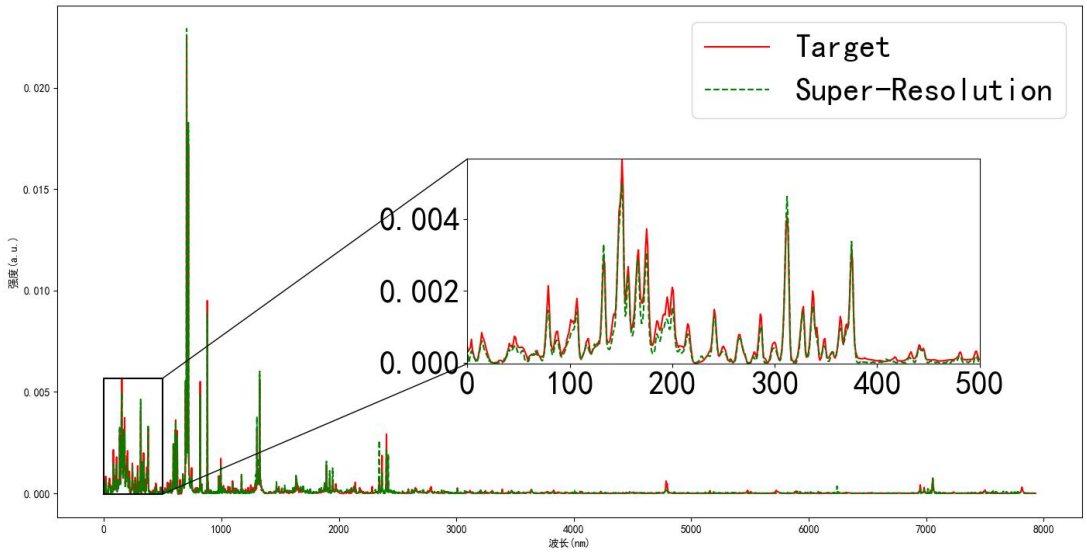


**(d)循环模型**

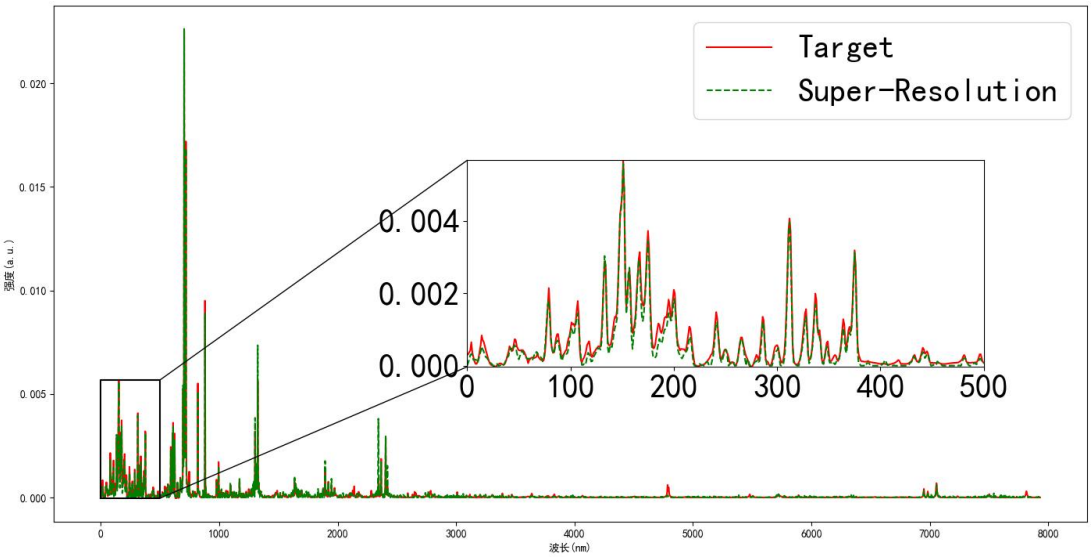


**(e)引导注意力模型**

**图5.2 各模型传递结果**

上述五种模型对光谱数据的传递效果中，除了卷积模型之外，其余四个模型的传递效果在折线图上与目标光谱数据基本一致，无法通过肉眼区分。但对于卷积模型，由于模型深度较浅，模型参数较少，因此在有限轮次中并不能很好的学习到模型特征并对光谱数据进行有效传递。该模型的优势在于浅层结构和少量的参数带来的训练速度提升和预测速度快，缺点同样由于深度和参数数量而导致收敛缓慢，完整训练时间花费反而上升。对卷积网络进行800轮次的训练后模型传递效果如图5.3所示。

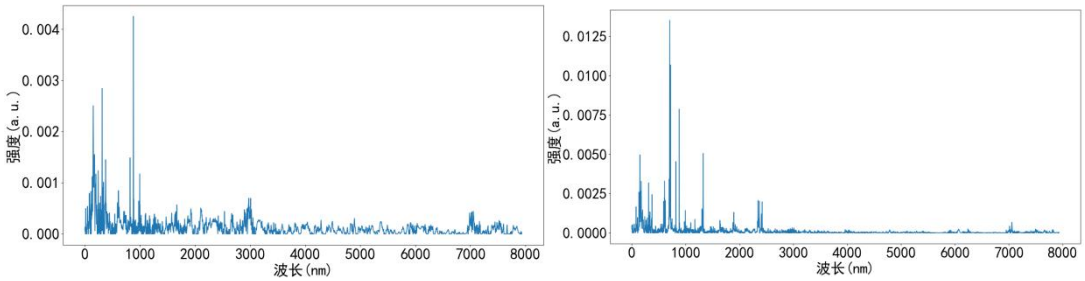


**(a)100轮次** **(b)800轮次**

**图5.3 不同轮次的卷积模型效果**

由于上述四种模型对光谱数据的传递效果非常显著，其优劣无法简单通过折线图观察出来，因此本设计通过PSNR对模型光谱数据传递效果进行评价，评价结果如图5.4所示，图中结果由五个模型以及双三次插值法通过模型大小和PSNR评价综合构成。双三次插值法作为传统插值法超分辨率方式，常用来作为超分辨率传递评价的基准指标，在光谱数据传递方面的PSNR评价为63.25；在所有模型中，最低的卷积模型PSNR为65，最高的循环模型PSNR为80.06，均高于传统的双三次插值法，所以利用深度学习对光谱数据进行超分辨率传递是很有效的。

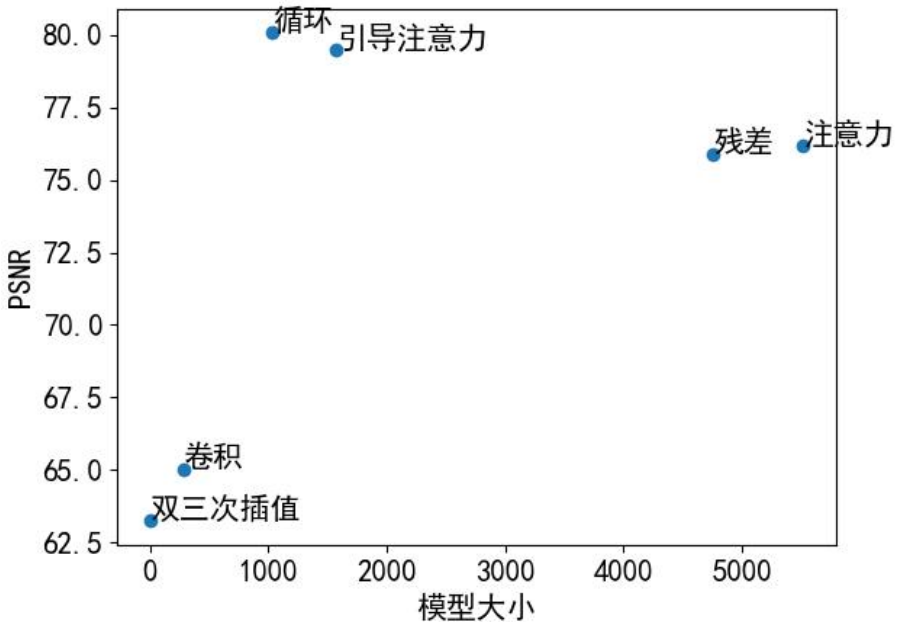


**图5.4 模型大小与PSNR综合评价**

综合考虑模型大小以及评价指标高低，循环网络与引导注意力网络以适量的模型体积完成了优秀的大样本光谱数据超分辨率传递效果，选取传递效果最佳的循环网络与目标光谱数据进行比较，比较结果如图5.5所示，图中红色实线为目标光谱数据，绿色虚线为传递结果，从图中可以看出循环模型对光谱数据的传递效果上，在高值段能够完美贴合目标光谱数据；在中值段整体偏低一些，但波形与

目标数据完全一致；在低值段能够很好的复现目标光谱数据的细节。

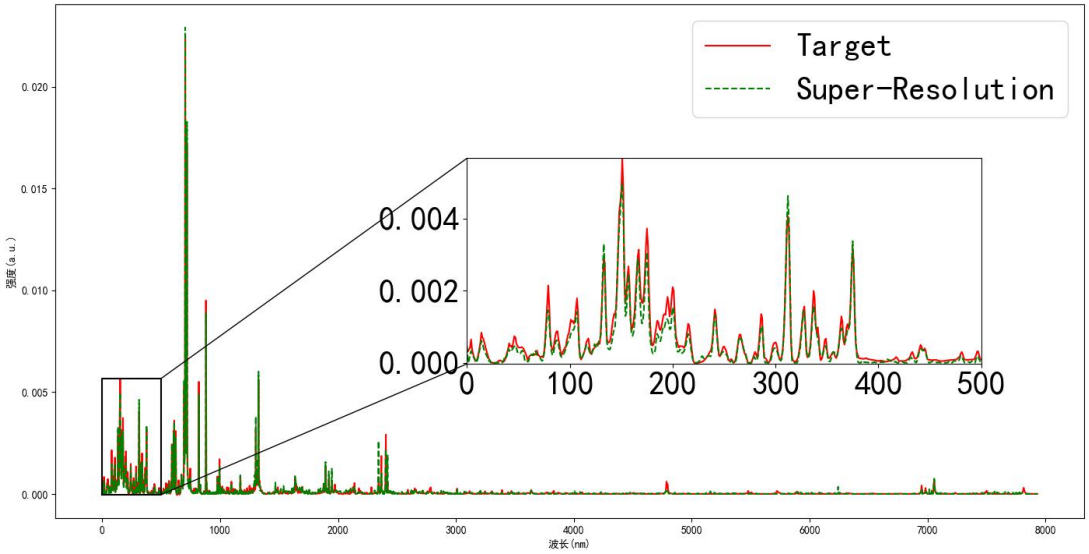


**图5.5 循环模型与目标光谱数据的对比**

上述模型按照模型大小、参数数量、网络深度、评价指标等综合信息进行评价的结果如表5-1所示。看以看出，针对小样本光谱数据改进后的模型在大样本光谱数据传递上也出现了优秀的效果。

**表5-1 在大样本光谱数据下的各模型综合性能比较**

| 传递方法 | 模型大小(KB) | 参数数量（个） | 网络深度（层） | PSNR |
|---|---|---|---|---|
| 卷积模型 | 286 | 1.064M | 3 | 65.00 |
| 残差模型 | 4757 | 1.618M | 12 | 75.89 |
| 注意力模型 | 5517 | 1.710M | 25 | 76.16 |
| 循环模型 | 1033 | 1.156M | 4 | 80.06 |
| 引导注意力模型 | 1574 | 2.317M | 9 | 79.49 |
| 双三次插值法 | / | / | / | 63.25 |

## 5.2 不同维度光谱数据传递效果分析

考虑到超分辨率算法中，亚像素卷积、二维卷积核等操作对二维数据处理的优越性能，本设计考虑从输入数据处理方面，将光谱数据处理为二维数据伪灰度图进行传递。原始数据和目标数据的伪灰度如图5.6所示。

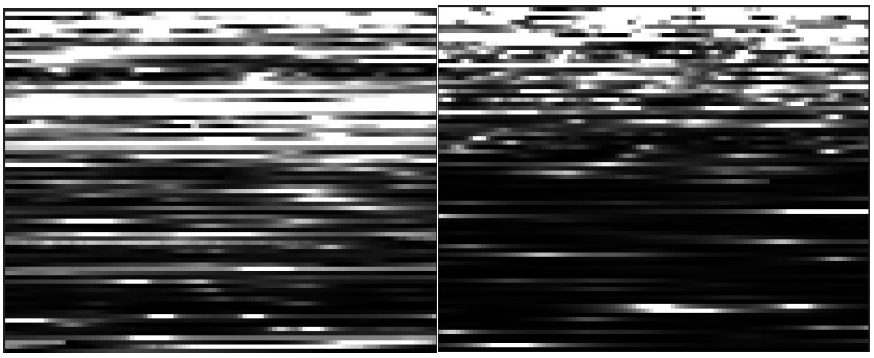

**(a)原始光谱数据伪灰度图　　(b)目标光谱数据伪灰度图**

**图5.6 伪灰度图**

通过第三章介绍的流程对二位光谱数据进行传递，并将其转换回一维光谱数据，输出结果如图5.7所示，实验表明通过升维的方式对光谱数据进行恢复的效果并不理想，模型预测结果与真实值相差过大。通过对二维伪灰度图的观察也能看出，一维光谱数据原本在前后信息之间就含有联系，而二维数据的处理流程在图像两端，也就是裁剪处不但打破了原本一维光谱数据的连续性，同时也增加了没有关联系的跳跃信息，使得数据信息流失、掺杂严重，模型无法有效学习特征信息，导致传递效果非常不理想。所以本设计最终选用一维模型对光谱数据进行恢复。

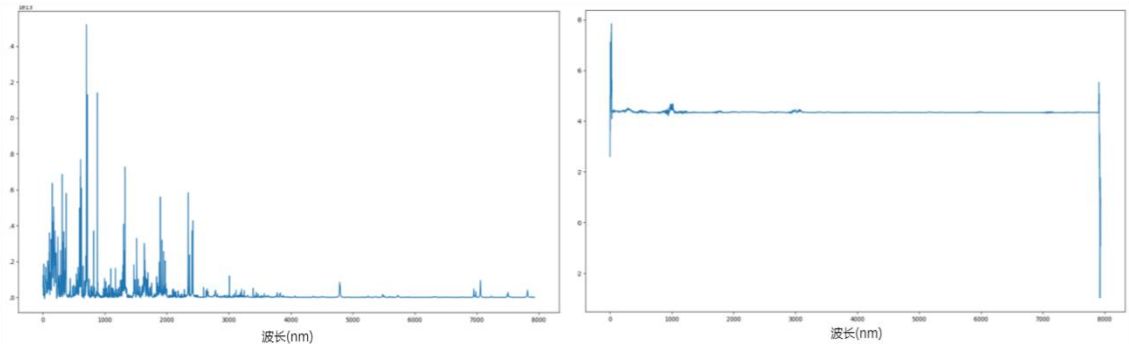


**(a)目标光谱数据　　(b)传递后光谱数据**

**图5.7 二维光谱数据传递结果**

## 5.3 小样本光谱数据传递效果分析

对小样本数据的传递主要使用循环网络和引导注意力网络作为传递模型，同时也加上了对大样本数据传递使用的卷积模型、残差模型、注意力模型作为对比，但通过实验得出这三种模型在对小样本数据恢复的效果并不理想，故不再给出折线图作为对比，仅在评价指标中体现。

本设计首先针对小样本数据建模数据过少的特点，充分考虑到光谱数据的前

后信息关联性，选用了处理序列信息非常优秀的循环网络进行光谱数据传递。循环网络模型传递结果如图5.8所示，PSNR评价指标为75.21，在小样本数据条件下的传递效果相较于大样本略有下降，模型对光谱数据波形的传递和值段的传递质量均有所下降，但相较于传统的双三次插值法传递效果要提升很多。

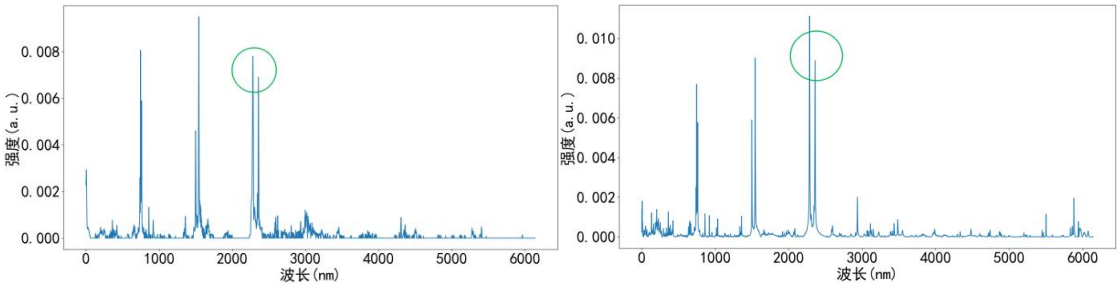


**(a)传递后光谱数据** **(b)目标光谱数据**

**图5.8 循环模型传递效果**

通过分析结果看以看出，小样本数据因为建模数据少的原因，在传递过程中没有办法很好的复现出目标光谱数据信息，比如在图5.8中标注出的数据区域中波峰就明显比目标光谱数据要低很多。因此，本设计在循环网络的基础上加入了引导注意力机制，人为引导模型关注2000-3000波长段，引导注意力模型的传递效果如图5.9所示，在引导波段的传递效果相较于之前明显的提升了，在PSNR评价指标方面也从75.21提升到了77.49。

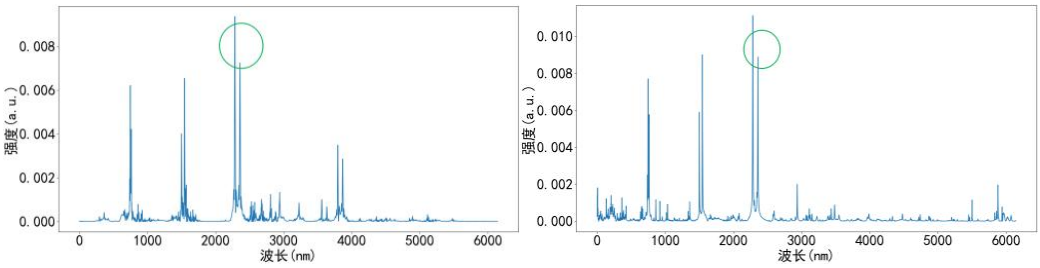


**(a)传递后光谱数据** **(b)目标光谱数据**

**图5.9 引导注意力模型传递效果**

所有模型对小样本数据传递的PSNR评价指标如图5.10所示，看以看出没有针对小样本数据进行改进的四个模型在传递效果上均出现了一定的下降，而在大样本数据传递中表现良好的循环网络在小样本数据传递中反而不如引导注意力模型。

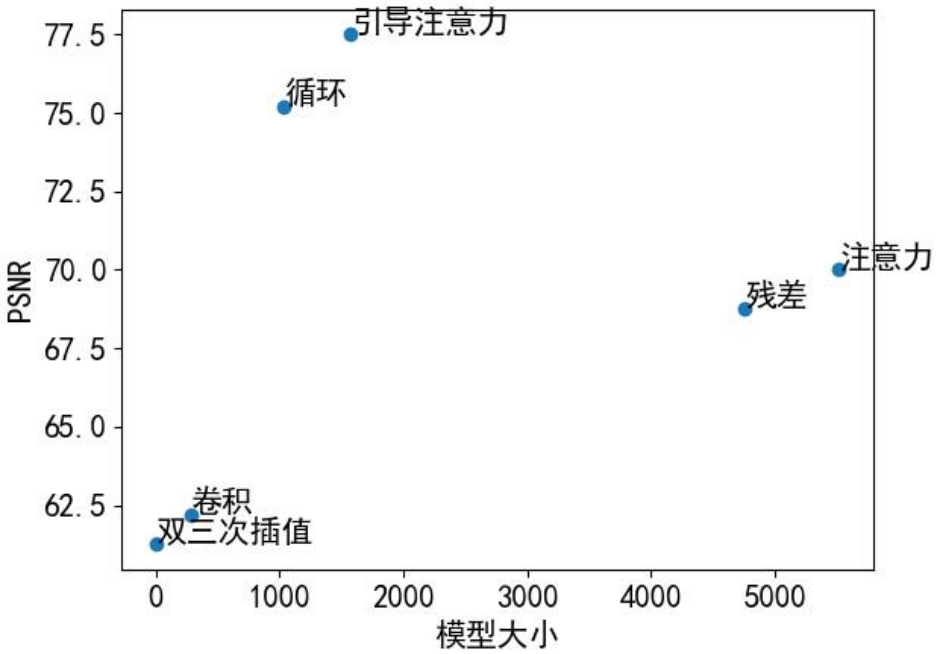


**图5.10 所有模型评价指标分析**

模型按照模型大小、参数数量、网络深度、评价指标等综合信息进行评价的结果如表5-2所示。看以看出在小样本条件下，单纯使用卷积模型对光谱数据进行传递的效果已经基本上与双三次插值法的效果一样了，所以对小样本光谱数据的传递还是有很大的难度的。

**表5-2 在小样本光谱数据下的各模型性能比较**

| 传递方法 | 模型大小(KB) | 参数数量（个） | 网络深度（层） | PSNR |
|---|---|---|---|---|
| 卷积模型 | 286 | 1.064M | 3 | 62.17 |
| 残差模型 | 4757 | 1.618M | 12 | 68.77 |
| 注意力模型 | 5517 | 1.710M | 25 | 70.01 |
| 循环模型 | 1033 | 1.156M | 4 | 75.21 |
| 引导注意力模型 | 1574 | 2.317M | 9 | 77.49 |
| 双三次插值法 | / | / | / | 61.25 |

# 6 结论与展望

本章主要是对本设计所提出的超分辨率光谱数据传递方法的传递效果进行综合总结与展望。通过本设计的研究得出了引导注意力网络模型在恢复光谱数据方面非常有效。同时针对目前本设计任然存在的不足之处提出后续的优化建议。

## 6.1 结论

本设计使用基于深度学习的超分辨率算法完成了对光谱数据从原始光谱数据到目标光谱数据的传递任务。探寻了适合用于一维光谱数据的超分辨率方法并在对光谱数据的超分辨率传递上取得了很好的效果。

不同于目前绝大多数用于二维数据的图像超分辨率模型，本设计所使用的一维超分辨率模型能够在一维光谱数据传递方面取得很好的效果，成功解决了光谱数据在二维超分领域效果不好的问题。本设计通过使用不同超分辨率模型进行比较，最终找到既能够兼顾传递效果，同时在模型体积、预测速度上综合表现良好的引导注意力网络模型。

综上所述，本设计充分探寻了基于超分辨率算法的光谱数据传递方法，在光谱数据传递方面通过传递将原始光谱数据传递到目标光谱数据，有效减少了因为外部因素导致的同一光谱数据获取结果存在差一的问题，为后续光谱数据应用提供了便利。

## 6.2 展望

本设计在光谱数据超分辨率传递方面，对大样本数据的传递效果非常显著，但对于小样本数据的传递效果尽管可以传递出大致波形与值段，但是整体效果并不理想。因此建议进一步展开的研究主要针对小样本数据的传递效果上，寻找一种能够在少量样本中有效学习特征并进行传递的超分辨率模型。

# 参考文献

[1]车永飞, 张明林, 叶发旺, 等. 面向铀矿地质应用的航空高光谱数据与伽马能谱数据协同应用研究[J]. 铀矿地质, 2023, 39(01)：110-118.

[2]Shaidullina Amina F,Sharipova Alsu R,Volkov Mihael Yu,etal. Photoisomerization of 1,2-Di(4-pyridyl)ethylene According to NMR and UV Spectroscopy Data and Density Functional Modeling[J]. Photochemistry and photobiology, 2023.

[3]Goffin Nicolas,Buache Emilie,Charpentier Celine,etal. Trajectory Interference for Unraveling Dynamic Biological Processes from Raman Spectral Data[J]. Analytical chemistry,2023.

[4]王瑾杰, 丁建丽, 葛翔宇, 等. 分数阶微分技术在机载高光谱数据估算土壤含水量中的应用[J]. 光谱学与光谱分析, 2022, 42(11)：3559-3567.

[5]周婷. 基于LIBS的类火星矿物光谱和模型传递及定量分析算法研究[D]. 山东：山东大学, 2022.

[6]周思寒, 胡新宇, 汤斌, 等. 一种基于EWMA-PCA的水质光谱数据标准化方法研究[J]. 光谱学与光谱分析, 2020, 40(11)：3443-3450.

[7]曹春阳, 胡诚, 徐洪雨, 等. 基于卷积神经网络的单幅图像超分辨率重建算法综述[J]. 中国高新科技, 2022, (12)：105-110.

[8]Zhang Haodi,Rogozan Alexandrina,Bensrhair Abdelaziz. An enhanced N-point interpolation method to eliminate average precision distortion[J]. Pattern Recognition Letters,2022,158.

[9]谭政, 相里斌, 吕群波, 等. 一种基于频域的序列图像超分辨率增强方法[J]. 光学学报, 2017, 37(07)：91-96.

[10]Fan Zhang.Innovation of English teaching model based on machine learning neural network and image super resolution[J].Journal of Intelligent & Fuzzy Systems,2020,39(2)：1-12.

[11]Zhao Yonghao. An Improved Indoor Positioning Method Based on Nearest Neighbor Interpolation[J]. Network and Communication Technologies,2021,6(1).

[12]Gao Chao,Zhou Ri Gui,Li Xin,etal. Asymmetric scaling of a quantum image based on bilinear interpolation with arbitrary scaling ratio[J]. Quantum Information Processing,2022,21(7).

[13]Zhu Yubin,Dai Yonghang,Han Kaining,etal. An efficient bicubic interpolation implementation for real-time image processing using hybrid computing[J]. Journal of Real-Time Image Processing,2022,19(6).

[14]尚文文. 利用空域法对医学图像进行处理[J]. 中国科技信息, 2012(22)：87.

[15]Charles Han,Bo Sun,Ravi Ramamoorthi,etal. Frequency domain normal map filtering[J]. ACM Transactions on Graphics (TOG),2007,26(3).

[16]Kannoth Sreekala,H C Sateesh Kumar,K B Raja. Low light image enhancement using curvelet transform and iterative back projection[J]. Scientific reports,2023,13(1).

[17]Datta Diptojit,Hosseinzadeh Ali Zare,Cui Ranting,etal. Railroad Sleeper Condition Monitoring Using Non-Contact in Motion Ultrasonic Ranging and Machine Learning-Based Image Processing[J]. Sensors,2023,23(6).

[18]叶文海, 林红波. 基于低维流形学习的地震数据重构[J]. 吉林大学学报(信息科学版), 2022, 40(06)：898-907.

[19]Chao Dong,Chen Change Loy,Kaiming He,etal.Image Super-Resolution Using Deep Convolutional Networks[J]. IEEE,2016,38(2):295-307.

[20]Bee Lim,Sanghyun Son,Heewon Kim,etal.Enhanced Deep Residual Networks for Single Image Super-Resolution[C].USA:IEEE,2017

[21]TONG Tong,Gen Li,Xiejie Liu,etal.Image super-resolution using dense skip connections[C].USA:IEEE,2017.
[22]Christian Ledig, Lucas Theis, Ferenc Huszar,etal.Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network[C].USA:IEEE,2017.
[23]Yulun Zhang,Kunpeng Li,Kai Li,etal.Image Super-Resolution Using Very Deep Residual Channel Attention Networks[C].Germany:Springer,2018.
[24]黎志伟. 基于注意力机制与改进型卷积的图像超分辨率重建[D]. 云南：云南师范大学, 2022.
[25]Ying Tai,Jian Yang,Xiaoming Liu.Image Super-Resolution via Deep Recursive Residual Network[C].USA:IEEE,2017.
[26]Guo Y.,Chen J.,Wang J.,etal.Closed-loop matters: Dual regression networks for single image super-resolution[J]. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition,2020:5406-5415.
[27]彭博, 卢景琦. 基于LIBS技术的银合金分类及定量分析研究[J]. 武汉理工大学学报, 2023, 45(01)：10-16.
[28]Diederik P. Kingma,Jimmy Ba. Adam: A Method for Stochastic Optimization.[J]. CoRR, 2014, abs/1412.6980.
[29]李婉婷, 林志成, 姜东, 等. 一种基于峰值信噪比的某试验现场监控采集图像对比算法设计[J]. 中国科技信息, 2023, (01):115-118.
[30]Hou Shaoxiong,Xiao Song,Dong Wenqian,etal. Multi-level features fusion via cross-layer guided attention for hyperspectral pansharpening[J]. Neurocomputing,2022,506.